

Михайловский Илья Евгеньевич

ML-инженер, NLP и LLM

Москва · офис, гибрид или удалённо · английский C1

Telegram: @lluuuuaa · ilyamihailovsy@gmail.com · github.com/lluuuuaa

О СЕБЕ

Учусь на прикладной математике и информатике в Московском политехе, выпускаюсь в 2029 году. Python в продакшене пишу с 2024 года, а с января 2026 веду LLM-слой B2B-продукта, где на каждое входящее сообщение работает конвейер из восьми вызовов модели со строгим JSON-schema выводом, агентом и роутером моделей. Сами модели пишу с нуля на PyTorch. В финале AIDAO 2025 собирал оссирансу-карту в bird's-eye view по камерам беспилотника и получил IoU 0.5606 при 0.564 у победителя олимпиады. Алгоритмическая база олимпиадная, на C++.

НАВЫКИ

- **ML и DL.** PyTorch, NumPy, pandas, matplotlib. Обучение с нуля и transfer learning, mixed precision, аугментации, подбор лосса под метрику, калибровка порога, дисбаланс классов, ResNet и FPN, сегментация, IoU
- **NLP и LLM.** LLM-пайплайны в проде, prompt engineering, строгий JSON-schema output, классификация и extraction, RAG, эмбединги и pgvector, агенты и tool calling, MCP, роутинг моделей с фолбэками, оценка стоимости и латентности
- **Инженерия.** Python, FastAPI, asyncio, PostgreSQL и SQL, Redis, Docker, CI/CD, Linux, Git, pytest
- **Математика и алгоритмы.** Теория вероятностей, матстатистика, линейная алгебра, методы оптимизации, C++, алгоритмы и структуры данных, оценка сложности

ОПЫТ РАБОТЫ

ReachFlow, ML/NLP и backend инженер

с января 2026

B2B SaaS, ИИ-ассистент, который ведёт продающие переписки в Telegram · reachflow.tech

- Собрал **конвейер диалога**, где на каждое входящее сообщение уходит восемь вызовов модели. Классификатор размечает состояние лида по 16 типам событий с якорем на сообщение и confidence, факты извлекаются по 18 типизированным ключам, а ответ пишет стратег, переписывает гуманизатор и проверяет ревьюер.
- **Удешевил ход.** Пять классификаторных вызовов слил в два, потому что одна модель умеет отдать несколько секций одним объектом. Вызовов на сообщение стало восемь вместо десяти, а входных символов на стадии классификации ушло меньше, от 14 до 43 процентов в зависимости от задачи. Каждая секция при этом сохранила свой режим отказа.
- Сделал **строгий структурированный вывод**. В реестре 25 LLM-задач и 22 схемы на pydantic, схемы нормализуются под strict-режим вендоров, а ответ проверяется у меня, и его нарушение считается повторяемой ошибкой. Исполнитель умеет ретраи и каскад фолбэков между вендорами, каждая попытка попадает в трейс с моделью, латентностью и стоимостью.
- Собрал **ИИ-агента с инструментами**. Реестр ToolSpec остаётся единственным источником правды сразу для блока инструментов в промпте, гейта привилегий по риску, границы доверия и MCP-эндпоинта. У оркестратора есть бюджет вызовов.
- Разобрал провал **семантического гейта**. Косинусная близость на эмбедингах text-embedding-3-small в pgvector с HNSW отбраковывала 55 кандидатов из 63, потому что мерила формат и длину текста вместо релевантности. Я перевёл гейт из блокирующего в наблюдательный и оставил решение за LLM-квалификацией.

Фриланс, Python-разработчик

с июля 2024

- Телеграм-бот-консультант для дистрибьютора пластиковых окон. Внутри **RAG** на PostgreSQL с векторным поиском по базе знаний и интеграция с Битрикс24. По оценке заказчика бот закрыл около 80% типовых консультаций.

Near AI, разработчик решений на C++

с июня 2023 по июль 2024

- Готовил алгоритмические решения на C++ как обучающие данные для AI-платформы. Оптимизировал по времени и памяти, разбирал асимптотику, ревьюил чужой код в международной команде.

ML-ПРОЕКТЫ И СОРЕВНОВАНИЯ

AIDAO 2025, международная олимпиада по ИИ и анализу данных (ФКН НИУ ВШЭ, Яндекс Образование) ноябрь 2025
Финал очно, 32 часа, топ-30 команд из 248 заявок от участников из 14 стран. Задачу ставила команда беспилотных технологий Яндекса, нужно было построить оссирансу-карту в bird's-eye view по камерам автомобиля со скором по IoU. Решение на PyTorch с нуля.

- Реализовал **Lift-Splat-Shoot**. Общий для камер ResNet-50 сливает уровни /8 и /16 через FPN, depth-head раскладывает глубину на 64 бина с обучаемой температурой softmax, признаки дифференцируемо разлетаются в BEV-сетку 188×126. Камеры сливаются через max и mean с SE-блоком, декодер на dilated residual-блоках.
- Главный прирост дала **покадровая калибровка** вместо фиксированной. Геометрия проекции пересчитывается на каждом кадре из *intrinsics* и *car_to_cam*, а сетка пикселей переносится в координаты исходного изображения, потому что у четырёх камер разные разрешения.
- Лосс собрал из BCE с *pos_weight* по балансу классов и $0.3\times$ дифференцируемого surrogate mIoU, то есть оптимизировал ровно ту метрику, по которой считался скор. Учил AdamW с раздельными lr для backbone и голов, с cosine annealing и AMP, порог калибровал свипом по валидации.
- На скрытом тесте вышло **IoU 0.5606**, у команды-победителя олимпиады 0.564. Инференс 2000 кадров занимает 1,7 минуты на одной GPU.

ОБРАЗОВАНИЕ И КУРСЫ

Московский политехнический университет, прикладная математика и информатика, выпуск 2029. **НИУ ВШЭ, ФКН**, вольнослушатель ПМИ. В 2025 году прошёл **Deep Learning School** ФПМИ МФТИ, Январскую научную школу **ОЦ «Сириус»** на 92 академических часа и годовой курс **Т-Поколения «Алгоритмы»**, параллель В.