

Михайловский Илья Евгеньевич

ML-инженер, NLP и LLM

Москва · офис, гибридно или удалённо · английский C1

Telegram: @iluuuuuaa · ilyamihailovsky@gmail.com · github.com/iluuuuuaa

О СЕБЕ

Обучаюсь на направлении «Прикладная математика и информатика» в Московском политехе, выпускаюсь в 2029 году. Python в продакшене пишу с 2024 года. Основал ReachFlow, платформу ИИ-агентов продаж, и сам реализовал агентов, LLM-слой диалога и продуктовый бэкэнд. Писал модели с нуля на PyTorch, финалист AIDAO 2025 с IoU 0.5606 при 0.564 у победителя. Занимаюсь наукой, написал статью по молекулярно-динамическому моделированию алюминиевой матрицы с включением Fe₄Al₁₃, репозиторий `physics_md_al_fe`.

НАВЫКИ

- ML и DL.** PyTorch, NumPy, pandas, matplotlib. Обучение с нуля и transfer learning, mixed precision, аугментации, подбор лосса под метрику, калибровка порога, дисбаланс классов, ResNet и FPN, сегментация, IoU
- NLP и LLM.** LLM-пайплайны в проде, prompt engineering, строгий JSON-schema output, классификация и extraction, RAG, эмбединги и pgvector, агенты и tool calling, MCP, роутинг моделей с фолбэками, оценка стоимости и латентности
- Инженерия.** Python, FastAPI, asyncio, PostgreSQL и SQL, Redis, Docker, CI/CD, Linux, Git, pytest
- Математика и алгоритмы.** Теория вероятностей, матстатистика, линейная алгебра, методы оптимизации, C++, алгоритмы и структуры данных, оценка сложности

ОПЫТ РАБОТЫ

ReachFlow, ML/NLP и backend инженер

с января 2026

B2B SaaS, ИИ-ассистент, который ведёт продающие переписки в Telegram · reachflow.tech

Конвейер диалога. На входящее сообщение уходит шесть-семь вызовов модели. Гейт решает, созрел ли ход, классификатор размечает состояние лида по 16 типам событий, факты извлекаются и взвешиваются по 18 ключам, затем ответ пишет стратег, переписывает писатель и проверяет ревьюер. Два вызова условные, они пропускаются, когда взвешивать нечего и проверять нечего. Реестр держит 25 задач, 22 строгие схемы на pydantic и 43 инструмента агента, из которых 10 помечены опасными.

Удешевление хода. Раньше уходило десять-одиннадцать вызовов. Я слил пять классификаторных обращений в два, потому что одна модель отдаёт несколько секций одним объектом, и это убрало дублирование истории диалога в промптах. Экономия входных символов вышла 14 процентов на коротком ходе, 38 на типовом и 43 на тяжёлом треде.

Чтение сайтов в контекст. Написал агента, который забирает страницу по ссылке из переписки прямо в контекст диалога, и отдельный сервис рендеринга на Playwright и Chromium под него. Каскад из четырёх ступеней останавливается по порогу качества, а не на первом успехе, иначе заглушка Cloudflare уехала бы в промпт как содержимое сайта. В модель идёт типизированная карточка из шести полей с выдержкой в 1200 символов, это граница доверия против инъекций со стороннего ресурса.

Организация контекста. Под бюджет промпта контекст деградирует ступенями, а не режется по длине: списки укорачиваются по кругу, и только затем выбрасываются поля по таблице из 44 приоритетов. Запреты выведены из ранжирования по репликам лида, иначе случайная фраза вымывала бы из промпта нужный запрет.

Фриланс, Python-разработчик

с июля 2024

- Telegram-бот-консультант для дистрибьютора пластиковых окон. **RAG** на PostgreSQL с векторным поиском по базе знаний и интеграция с Битрикс24. По оценке заказчика закрыл около 80% типовых консультаций.

Near AI, разработчик решений на C++

с июня 2023 по июль 2024

- Готовил алгоритмические решения на C++ как обучающие данные для AI-платформы. Оптимизировал по времени и памяти, разбирал асимптотику, ревьюил код в международной команде.

ML-ПРОЕКТЫ И СОРЕВНОВАНИЯ

AIDAO, Олимпиада по искусственному интеллекту и анализу данных

2025

Яндекс Образование и факультет компьютерных наук НИУ ВШЭ. Финалист, очный финал с 28 по 30 ноября 2025, 32 часа, топ-30 команд из 248 заявок от участников из 14 стран. Задачу ставила команда беспилотных технологий Яндекса, нужно было построить occupancy-карту в bird's-eye view по камерам автомобиля со скором по IoU. Решение с нуля на PyTorch, репозиторий `aidao-2025-bev-occupancy`.

- Реализовал **Lift-Splat-Shoot**. Общий для камер ResNet-50 сливает уровни /8 и /16 через FPN, depth-head раскладывает глубину на 64 бина с обучаемой температурой softmax, признаки дифференцируемо разлетаются в BEV-сетку 188×126. Камеры сливаются через max и mean с SE-блоком, декодер на dilated residual-блоках.
- Главный прирост дала **покадровая калибровка** вместо фиксированной. Геометрия проекции пересчитывается на каждом кадре из *intrinsics* и *car_to_cam*, а сетка пикселей переносится в координаты исходного изображения, потому что у четырёх камер разные разрешения.
- Лосс собрал из BCE с *pos_weight* по балансу классов и 0.3× дифференцируемого surrogate mIoU, то есть оптимизировал ту метрику, по которой считался скор. Учил AdamW с отдельными lr для backbone и голов, с cosine annealing и AMP, порог калибровал свипом по валидации.
- На скрытом тесте вышло **IoU 0.5606**, у команды-победителя олимпиады 0.564. Инференс 2000 кадров занимает 1,7 минуты на одной GPU.

ОБРАЗОВАНИЕ И КУРСЫ

Московский политехнический университет, транспортный факультет, образовательная программа «Прикладная математика и информатика», выпуск 2029. НИУ ВШЭ, факультет компьютерных наук, вольнослушатель курсов той же программы. **Образовательный центр «Сириус»**, профильный модуль программы «Январская научная школа по математике и программированию», 92 академических часа, январь 2025. **Deep Learning School** ФПМИ МФТИ, 2025. **T-Образование**, программа «Т-Поколение», курс «Алгоритмы», параллель В, 2025.