

Михайловский Илья Евгеньевич

ML Engineer (NLP / LLM)

Москва · офис / гибрид / удалённо · английский C1

Telegram: @iluuuuuu · ilyamihailovsky@gmail.com · github.com/iluuuu

О СЕБЕ

Студент ПМИ (Московский политех, выпуск 2029). С 2024 года пишу Python в продакшене, с начала 2026-го веду LLM-слой B2B-продукта: конвейер из 8 вызовов модели на входящее сообщение, strict JSON-schema output, агент с реестром инструментов и MCP, роутинг моделей с фолбэками, трассировка стоимости вызовов. Модели пишу с нуля на PyTorch: финалист AIDAO 2025 (ФКН НИУ ВШЭ и Яндекс Образование), оссирансу в bird's-eye view по камерам беспилотника — IoU 0.5606 при 0.564 у победителя. Алгоритмическая база — C++, олимпиадное программирование.

НАВЫКИ

- **ML / DL:** PyTorch, NumPy, pandas, matplotlib; обучение с нуля и transfer learning, mixed precision, аугментации, подбор лосса под метрику, калибровка порога, дисбаланс классов; ResNet / FPN, сегментация, IoU
- **NLP / LLM:** LLM-пайплайны в проде, prompt engineering, strict JSON-schema output, классификация и extraction, RAG, эмбединги + pgvector, LLM-агенты и tool calling, MCP, роутинг моделей и fallback, оценка cost / latency
- **Инженерия:** Python, FastAPI, asyncio, PostgreSQL / SQL, Redis, Docker, CI/CD, Linux, Git, pytest
- **Математика и алгоритмы:** теория вероятностей, матстатистика, линейная алгебра, методы оптимизации; C++, алгоритмы и структуры данных, оценка сложности

ОПЫТ РАБОТЫ

ReachFlow — ML/NLP & Backend Engineer

Янв 2026 — наст. время

B2B SaaS: ИИ-ассистент, который ведёт продающие переписки в Telegram · reachflow.tech

- Построил **LLM-конвейер диалога** — 8 вызовов модели на входящее сообщение: гейт батча, классификатор состояния лида (16 типов событий с якорем на сообщение и confidence), извлечение и взвешивание фактов (18 типизированных ключей), стратег → гуманизатор → ревьюер, планировщик отправок.
- **Снизил стоимость хода:** слил пять классификаторных вызовов в два — одна модель отдаёт несколько секций одним объектом; 10 вызовов на сообщение стало 8, входных символов на стадии классификации на 14–43% меньше, при этом каждая секция сохранила собственный режим отказа.
- Сделал **strict structured output**: реестр из 25 LLM-задач и 22 JSON-схем на pydantic, нормализация схем под strict-режим и валидация ответа на своей стороне (нарушение схемы — retryable); исполнитель с ретраями, каскадом фолбэков между вендорами и трейсом каждой попытки (модель, latency, retry, стоимость).
- Собрал **ИИ-агента с инструментами**: реестр ToolSpec — единственный источник правды для блока инструментов в промпте, гейта привилегий по риску, границы доверия и MCP-эндпоинта; оркестратор с бюджетом вызовов.
- Разобрал провал **семантического гейта**: косинусная близость на эмбедингах (text-embedding-3-small, pgvector / HNSW) отбраковывала 55 кандидатов из 63, потому что мерила формат и длину текста, а не релевантность — перевёл гейт из блокирующего в наблюдательный.

Freelance Python Developer

Июль 2024 — наст. время

- Telegram-бот-консультант для дистрибьютора пластиковых окон: **RAG** на PostgreSQL с векторным поиском по базе знаний, интеграция с CRM Bitrix24; по оценке заказчика закрыл ~80% типовых консультаций.

Near AI — разработчик решений на C++

Июнь 2023 — Июль 2024

- Алгоритмические решения на C++ как обучающие данные для AI-платформы: оптимизация по времени и памяти, разбор асимптотики, code review в международной команде.

ML-ПРОЕКТЫ И СОРЕВНОВАНИЯ

AIDAO 2025 — Международная олимпиада по ИИ и анализу данных (ФКН НИУ ВШЭ, Яндекс Образование) Ноя 2025
Финал: топ-30 команд из 248 из 14 стран, 32 часа очно. Задача команды беспилотных технологий Яндекса — оссиранс-карта в bird's-eye view по камерам автомобиля, метрика IoU. PyTorch, решение с нуля.

- Реализовал **Lift-Splat-Shoot**: общий для камер ResNet-50 с FPN-слиянием уровней /8 и /16, depth-head на 64 бина глубины с обучаемой температурой softmax, дифференцируемый splat признаков в BEV-сетку 188×126, фьюжн камер max + mean с SE-блоком, декодер на dilated residual-блоках.
- Основной прирост дала **покадровая калибровка** вместо фиксированной: геометрия проекции пересчитывается на каждом кадре из *intrinsics* и *car_to_cam*, с переносом сетки пикселей в координаты исходного изображения.
- Лосс — BCE с pos_weight по балансу классов + 0.3× дифференцируемый surrogate mIoU: оптимизировал ровно ту метрику, по которой считался скор. AdamW с отдельными lr для backbone и голов, cosine annealing, AMP, калибровка порога свипом по валидации.
- Итог — **IoU 0.5606** на скрытом тесте (у команды-победителя олимпиады 0.564); инференс 2000 кадров за 1,7 мин на одной GPU.

ОБРАЗОВАНИЕ И КУРСЫ

Московский политехнический университет — прикладная математика и информатика, выпуск 2029 · **НИУ ВШЭ, ФКН** — вольнослушатель курсов ПМИ · **Deep Learning School** (ФПМИ МФТИ), 2025 · **ОЦ «Сириус»** — Январская научная школа по математике и программированию, 92 ак. ч., 2025 · **Т-Поколение** (Т-Банк) — «Алгоритмы», параллель В, 2025