

Михайловский Илья Евгеньевич

ML-инженер, NLP и LLM

Москва · офис, гибридно или удалённо · английский C1

Telegram: @iluuuuaa · ilyamihailovsky@gmail.com · github.com/iluuuuaa

О СЕБЕ

Учусь на программе «Прикладная математика и информатика» в Московском политехе, выпуск в 2029 году. С 2024 года пишу Python для работающих сервисов. Основал ReachFlow и разрабатываю его backend, ИИ-агентов и обработку диалогов. Обучал модели с нуля на PyTorch. Финалист AIDAO 2025.

НАВЫКИ

- ML и DL: PyTorch, NumPy, pandas, matplotlib; обучение с нуля и transfer learning, mixed precision, аугментации, подбор лосса под метрику, калибровка порога, дисбаланс классов, ResNet и FPN, сегментация, IoU
- NLP и LLM: обработка диалогов, prompt engineering, ответы по JSON Schema, классификация и извлечение фактов, RAG, эмбединги и pgvector, агенты и tool calling, MCP, выбор моделей и резервных провайдеров, оценка стоимости и латентности
- Инженерия: Python, FastAPI, asyncio, PostgreSQL и SQL, Redis, Docker, CI/CD, Linux, Git, pytest
- Математика и алгоритмы: теория вероятностей, матстатистика, линейная алгебра, методы оптимизации, C++, алгоритмы и структуры данных, оценка сложности

ОПЫТ РАБОТЫ

ReachFlow, Founder

январь 2026 - настоящее время

B2B SaaS для работы с обращениями и диалогами в Telegram · reachflow.tech

- Разработал обработку диалога: проверка готовности ответа, классификация по 16 типам событий, извлечение и оценка фактов по 18 ключам, планирование ответа, его написание и проверка. Два этапа запускаются по необходимости. В реализованной версии на сообщение приходится шесть-семь вызовов; реестры содержат 25 задач, 22 схемы Pydantic и 43 инструмента, включая 10 с повышенным риском.
- Объединил пять классификаторных обращений в два и убрал повторную передачу истории диалога. Число вызовов сократилось с десяти-одиннадцати до шести-семи. Объём входного текста уменьшился на 14% для короткого диалога, на 38% для типового и на 43% для длинного.
- Написал агента для чтения сайтов и отдельный рендерер на Playwright и Chromium. Четыре способа получения страницы проверяются по качеству содержимого, чтобы служебная страница Cloudflare не попала в контекст. Модель получает карточку из шести полей с выдержкой до 1200 символов; внешнее содержимое отделено от инструкций.
- Настроил сокращение контекста под бюджет промпта: сначала укорачиваются списки, затем удаляются поля по 44 приоритетам. Запреты сохраняются независимо от ранжирования по сообщениям собеседника.

Delnovo, Chief Technology Officer

июль 2023 - май 2026

- Разрабатывал коммерческих ботов для поддержки клиентов и автоматизации продаж. Для дистрибьютора пластиковых окон собрал RAG на PostgreSQL с векторным поиском по базе знаний и интеграцией с Битрикс24. По оценке заказчика бот автоматизировал около 80% типовых консультаций.

NEAR AI, Solutions Engineer

июнь 2023 - июль 2024

- Решал алгоритмические задачи на C++ для обучения децентрализованного ИИ. Оптимизировал время и память, оценивал асимптотику и проверял код участников международной команды.

ML-ПРОЕКТЫ И СОРЕВНОВАНИЯ

AIDAO 2025, финалист

ноябрь 2025

Олимпиада Яндекс Образования и ФКН НИУ ВШЭ. Топ-30 команд из 248 заявок от участников из 14 стран; очный финал с 28 по 30 ноября, 32 часа. Задача команды беспилотных технологий Яндекса: построить оссипансу-карту в bird's-eye view по камерам автомобиля. Метрика: IoU. Код: [aidao-2025-bev-occipancy](#).

- Реализовал Lift-Splat-Shoot с нуля на PyTorch. Общий для камер ResNet-50 объединяет уровни /8 и /16 через FPN; depth-head оценивает 64 интервала глубины с обучаемой температурой softmax. Признаки проецируются в BEV-сетку 188×126, камеры объединяются через max и mean с SE-блоком, декодер использует dilated residual-блоки.
- Главный прирост дала поккадровая калибровка. Геометрия проекции пересчитывается на каждом кадре из *intrinsics* и *car_to_cam*, а сетка пикселей переносится в координаты исходного изображения, потому что у четырёх камер разные разрешения.
- Функция потерь: BCE с pos_weight по балансу классов и 0.3× дифференцируемого surrogate mIoU. Обучал с AdamW, разными learning rate для backbone и голов, cosine annealing и AMP; порог выбирал на валидации.
- IoU на скрытом тесте: 0.5606; у победителя: 0.564. Обработка 2000 кадров занимает 1,7 минуты на одной GPU.

Лидеры цифровой трансформации 2026, задача №5

2026

Капитан команды xixi-square. Разработал алгоритм обнаружения препятствий по облакам точек 3D-лидара Pandar128 и интеграцию с ROS 2 Humble. Геометрия тоннеля и рельсов задаёт габарит движения; препятствия подтверждаются по нескольким кадрам. Решение упаковано в Docker. На синтетике организаторов найдены все 8 препятствий; на проверенных 15,7 км реальных записей ложных тревог не было.

Научная работа. Написал статью по молекулярно-динамическому моделированию алюминиевой матрицы с включением Fe₄Al₁₃. Код и материалы: [physics_md_al_fe](#).

ОБРАЗОВАНИЕ И КУРСЫ

Московский политехнический университет, транспортный факультет, образовательная программа «Прикладная математика и информатика», выпуск 2029. **НИУ ВШЭ**, факультет компьютерных наук, вольнослушатель курсов той же программы. **Образовательный центр «Сириус»**, профильный модуль программы «Январская научная школа по математике и программированию», 92 академических часа, январь 2025. **Deep Learning School** ФПМИ МФТИ, 2025. **Т-Образование**, программа «Т-Поколение», курс «Алгоритмы», параллель В, 2025.